GUI 测试智能体改进报告

项目概览

- **测试任务**：以本地运行的 BookStack 为被测 Web 应用，任务文件用自然语言给出操作步骤及预期现象；智能体需要判断页面行为是否符合要求，并返回 PASS 或 FAIL。
- **系统分工**： `browser-use` 与视觉语言模型负责操作已登录的浏览器、查找页面证据；评测框架负责准备场景、注入页面缺陷并记录结果。智能体接收任务名称、步骤和预期现象，不接收基准判定结果。
- **改进目标**：提高缺陷检出能力，同时降低单个用例的运行时间和模型 token 消耗。

评测设置

- **对照条件**：基线与改进版使用相同的 `dev` 任务集、 `deepseek-flash` 模型和 BookStack 场景。
- **测试内容**：四项任务覆盖个人主页的已创建页面数与搜索结果是否一致、新建图书后的列表、最近浏览顺序，以及搜索结果与图书内容是否一致。每项任务各运行正常页面（ `clean` ）和注入缺陷页面（ `bug` ），共八个 GUI 用例；预期结果分别为 PASS 和 FAIL。
- **运行与计分**：使用 `uv run pytest --agent my_agent` 运行改进版。评测器比较智能体判定与预期结果，统计正确率、缺陷检出率、误报率、耗时、token 用量和模型调用次数。后文指标仅统计八个 GUI 用例，不计入新增的回归单测。

改进方法

基线主要依赖视觉语言模型记住先前页面的信息，再从最终报告中提取判定。我保留了模型操作浏览器的方式，同时加入以下机制：

- **页面证据采集**：每次操作后调用 `capture_page(page)` ，记录页面数、搜索结果行、图书名称与描述、最近浏览顺序，以及图书内的章节和页面（ `agents/my_agent.py:43` ）。
- **最有用的一项改动**：跨页面时序断言。 `compare_observations()` 按访问顺序比较原始可见值（ `agents/my_agent.py:83` ）。“最近浏览”依次检查初始首页、Book2 详情和返回后的首页；“创建图书”依次检查表单、保存后的详情页和最终列表。它将依赖模型记忆的跨页关系转为可复核的断言，保留列表重复项，并在需要时检查顺序。
- **失败案例分析与修正**：在 `recently_viewed_book-bug` 的调试中，曾出现打开 Book2 后尚未返回首页、就用旧列表判 FAIL 的情况。旧首页快照被误当作操作后的证据，使结论虽然碰巧符合预期，却没有完成验证。为此，比较器只查找打开 Book2 之后的首页快照，找不到就延后判定（ `agents/my_agent.py:102` ）；回归测试覆盖了这一时序（ `tests/test_observations.py:5` ）。在缺陷页面上，Book2 移至首位后仍有两条“Chapter 2”记录缺失，因此 FAIL 有明确的页面依据。

- **减少额外开销**：证据齐备且页面更新稳定后停止智能体（ `agents/my_agent.py:167` ）；富文本 iframe 使用专用填写动作并核对内容（ `agents/my_agent.py:184` ），减少重复导航和模型调用。

关键实现节选如下：

改进点	代码节选	位置
页面证据采集	`observations.append(await capture_page(page))`	`agents/my_agent.py:169`
访问顺序约束	`observations[book_index + 1:]`	`agents/my_agent.py:102`
搜索结果比对	`Counter(search_items) == Counter(actual)`	`agents/my_agent.py:147`
证据齐备后停止	`active_agent.stop()`	`agents/my_agent.py:177`
富文本填写	`await editor.fill(text, timeout=5000)`	`agents/my_agent.py:187`

指标对比

下表汇总了相同任务集下基线与改进版的评测结果：

指标	基线	改进版
判定正确数	6/8（75%）	8/8（100%）
缺陷检出率	2/4（50%）	4/4（100%）
正常页面误报率	0/4（0%）	0/4（0%）
ERROR 数	1	0
平均每例耗时	143.4 秒	27.1 秒
平均每例 token	135,243	36,133
平均每例模型调用	11.1 次	3.9 次

与基线相比，平均耗时下降约 81%，token 用量下降约 73%，模型调用次数下降约 65%。数据来源为 `reports/baseline-20261017-211706/results.json` 和 `reports/my_agent-20261018-005111/results.json` 。

结论与展望

在八个 GUI 用例中，改进版全部判定正确，且耗时与 token 开销显著低于基线。后续可增加搜索结果顺序检查，并通过重复评测进一步完善断言覆盖与稳定性评估。